



MCD

# ¿Que es el aprendizaje supervisado?

Curso Aprendizaje Automático  
Aplicado

Julio Weissman

# Ejemplo

## Decidir si otorgar un crédito a un cliente

- *Cliente*: edad, genero, estado civil, ingreso mensual, otros creditos, lugar donde vive, número de hijos, ...
- *Salida esperada*: Sí / No

# Otro Ejemplo

## Decidir limite de crédito para un cliente

- *Cliente*: edad, genero, estado civil, ingreso mensual, otros creditos, lugar donde vive, número de hijos, ...
- *Salida esperada*: Un número real

# Entradas

- Cliente es una *instancia*  $x$ .
- Si tenemos un conjunto de instancias entonces  $x^{(i)}$ .

$$x \in X = X_1 \times X_2 \times \cdots \times X_n$$

$$x = (x_1, x_2, \dots, x_n)$$

# Salidas

- Salida  $y \in Y$ .
  - $Y = \mathbb{R}$  regresión,
  - $Y = \{F, V\}$  clasificación binaria,
  - $Y = \{C_1, C_2, \dots, C_k\}$  clasificación.

# Y porque aprendizaje supervisado

Porque asumimos que puedo contestar a las preguntas, si yo cuento con un conjunto de clientes previamente clasificados

$$CA = \{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(M)}, y^{(M)})\}$$

¿Y eso que significa?

# Formalizando

Asumimos que existe una función

$$f : X \rightarrow Y$$

desconocida.

# Formalizando

Del conjunto de todas las posibles instancias  $X$ , tenemos una muestra

$$X_T \subset X$$

$$X_T = \{x^{(1)}, x^{(2)}, \dots, x^{(M)}\}$$

los cuales provienen de un muestreo con distribución desconocida.



# Formalizando

Asumimos que los valores  $y^{(i)}$  que conocemos provienen de

$$y^{(i)} = f(x^{(i)}) + e$$

donde  $e$  es una variable aleatoria de distribución desconocida.

$$CA = \{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(M)}, y^{(M)})\}$$

# Formalizando

Y para el aprendizaje vamos a decidir usar algún modelo particular. Esto es, vamos a buscar una *hipótesis*:

$$h : X \times \Theta \rightarrow Y$$

donde  $\theta = (\theta_1, \dots, \theta_p)$  son los parámetros del modelo de aprendizaje.

# Aprendizaje supervisado

El aprendizaje supervisado consiste en seleccionar un modelo de aprendizaje, y ajustar un conjunto de parámetros  $\theta^*$  tal que:

$$h^* \approx f$$

que significa que

$$h_{\theta^*}(x) \approx f(x), \quad \forall x \in X$$

# Conjunto de hipótesis

Notese que si  $\theta$  es fija (constante), entonces

$$h_{\theta} : X \rightarrow Y$$

y por cada  $\theta$  diferente hay una función de un *conjunto de hipótesis*:

$$\mathcal{H} = \{h_{\theta} | \theta \in \Theta\}$$

y el aprendizaje consiste en seleccionar un  $h^* \in \mathcal{H}$

# Ejemplo

Si  $X = \mathbb{R}$  y

$$h_i(x) = w_i x + b_i$$

- ¿Cual es el vector  $\theta$ ?
- ¿Cual es la dimensión del conjunto  $\mathcal{H}$ ?

# Aquí viene la bronca

¿Que significa  $h^* \approx f$ ?

# Función de pérdida

$$loss : Y \times Y \rightarrow \mathbb{R}$$

que permite calcular la diferencia entre lo medido y lo estimado

$$loss(y, \hat{y})$$

idealmente

$$loss(f(x), h_{\theta}(x))$$

# Ejemplos de funciones de pérdida

- MSE:

$$loss(y, \hat{y}) = \frac{1}{2} (y - \hat{y})^2$$

- MAE:

$$loss(y, \hat{y}) = |y - \hat{y}|$$

- 0/1-loss:

$$loss(y, \hat{y}) = 0 \text{ si } y = \hat{y}, \text{ en otro caso } 1$$



# Error fuera de muestra

Decimos que  $f \approx h$  si  $E_o \approx 0$  donde

$$E_o = \mathbf{E}_X[\text{loss}(f(x), h(x))]$$

Pequeños detallitos:

- No conocemos  $f$
- No conocemos todos los valores de  $x \in X$

# Error en muestra

Lo que podemos medir es lo que sí conocemos

$$E_i = \frac{1}{M} \sum_{i=1}^M \text{loss}(y^{(i)}, h(x^{(i)}))$$

# Formalizando el aprendizaje

Decimos que  $f \approx h^*$  ssi

$$E_i(f, h^*) \approx 0$$

y

$$E_o(f, h^*) \approx E_i(f, h^*)$$

$$E_i(f, h^*) \approx 0$$

- Problema de optimización
- Encontrar  $h^*$  equivale a encontrar el vector de parámetros  $\theta^*$  tal que

$$\theta^* = \arg \min_{\theta \in \Theta} \frac{1}{M} \sum_{i=1}^M \text{loss}(y^{(i)}, h_{\theta}(x^{(i)}))$$

$$E_o(f, h^*) \approx E_i(f, h^*)$$

- Generalización
- Diferencia entre aprendizaje y optimización
- Vamos a usar una noción que parece una broma:

*Aprendizaje Probablemente Aproximadamente Correcto (PAC Learning)*